

线性回归的正则化.

• Loss function

$$J(w) = \sum_{i=1}^N \|w^T x_i - y_i\|^2 \quad \text{where } i=1, 2, \dots, N.$$

(最小二乘估计的估计): $\hat{w} = \underbrace{(X^T X)^{-1}}_{\text{①}} X^T Y$

①: 有时是不可逆的.

此处, N 个样本, $x_i \in \mathbb{R}^p$.

若 N 不是 $\gg p$, $\Rightarrow (X^T X)$ 不可逆, \rightarrow 过拟合.

若 $N \gg p$ $\Rightarrow (X^T X)$ 可逆.

1. 加约束
 2. 特征提取
 3. 正则化 (对 w 约束)
- ↑

• 所以引入正则化. (1. 不可逆问题 2. 过拟合问题)

1. 正则化的框架

<对 w 的约束>

$$J(w) + \lambda \underbrace{P(w)}_{\text{惩罚项}} \Rightarrow \arg\min_w [J(w) + \lambda P(w)]$$

1. L_1 正则化 / L_2 岭回归 (权值衰减)

$$P(w) = \|w\|_1$$

$$P(w) = \|w\|_2 = w^T w$$

(二范数)

$$J_2(w) = L(w) + \lambda P(w)$$

$$= \sum_{i=1}^N \|w^T x_i - y_i\|^2 + \lambda w^T w$$

$$= (w^T X^T - Y^T)(Xw - Y) + \lambda w^T w \rightarrow \text{实数}$$

$$= w^T X^T X w - \underbrace{w^T X^T Y - Y^T X w}_{\text{实数}} + Y^T Y + \lambda w^T w$$

$$= w^T X^T X w - 2 w^T X^T Y + Y^T Y + \lambda w^T w$$

$$= w^T (X^T X + \lambda I) w - 2 w^T X^T Y + Y^T Y$$

\downarrow
单位矩阵

$$\rightarrow \arg \min_w J_2(w)$$


$$\Rightarrow \frac{\partial J_2(w)}{\partial w} = 2(X^T X + \lambda I)w - 2X^T Y + 0 = 0$$

$$\Rightarrow (X^T X + \lambda I)w = X^T Y$$

$$\Rightarrow w = (X^T X + \lambda I)^{-1} X^T Y$$

岭回归的求解





$$f(w) = w^T x + b$$

$$y = f(w) + \varepsilon$$

$$\varepsilon \sim N(0, \sigma^2)$$

$$y_i | x, w \sim N(w^T x, \sigma^2)$$

贝叶斯线性模型的规则

• 当 y 看作证据.

• 给 w 一个先验: $w \sim N(0, \sigma^2)$

$$\text{贝叶斯规则} \rightarrow p(w|y) = \frac{p(y|w)p(w)}{p(y)}$$

• MAP (最大后验)

$$\arg \max_w p(w|y)$$

$$= \arg \max_w p(y|w)p(w)$$

$$\text{已知: } p(y|w) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y-w^T x)^2}{2\sigma^2}\right)$$

与 w 无关系, 省略掉.

$$p(w) = \frac{1}{\sqrt{2\pi}\sigma_0} \exp\left(-\frac{(w-d)^2}{2\sigma_0^2}\right) \\ \sim N(d, \sigma_0^2)$$

则有: $p(y|w) \cdot p(w)$

$$= \frac{1}{\sqrt{2\pi}\sigma} \cdot \frac{1}{\sqrt{2\pi}\sigma_0} \exp\left\{-\frac{(y-w^T x)^2}{2\sigma^2} - \frac{\|w\|^2}{2\sigma_0^2}\right\}$$

$$\hat{w} = \arg \max_w p(y|w) p(w)$$

$$\Rightarrow \arg \max_w \log \frac{1}{\sqrt{2\pi}\sigma} + \log \frac{1}{\sqrt{2\pi}\sigma_0} + \log \exp\{\dots\}$$

\Rightarrow 保留与 w 相关

$$\Rightarrow \arg \max_w -\left(\frac{(y-w^T x)^2}{2\sigma^2} + \frac{\|w\|^2}{2\sigma_0^2}\right)$$

$$\Rightarrow \arg \min_w \frac{(y-w^T x)^2}{2\sigma^2} + \frac{\|w\|^2}{2\sigma_0^2} \quad \underline{x \geq \sigma^2}$$

$$\Rightarrow (y-w^T x)^2 + \frac{\sigma^2}{\sigma_0^2} \|w\|^2$$

而我们的定义:

$$\hat{w}_{\text{MAP}} = \arg \min_w \sum_{i=1}^N (y_i - w^T x_i)^2 + \frac{\sigma^2}{\sigma_0^2} \|w\|^2$$

$$J_2(w) = \sum_{i=1}^N (w^T x_i - y_i)^2 + \lambda w^T w$$

\downarrow
 L_2

★ 正则化的LSE (最小二乘) \Leftrightarrow MAP (最大后验) $\left\{ \begin{array}{l} \text{先验} \sim \text{高斯分布} \\ \text{其中 noise} \sim N(0, \sigma^2) \end{array} \right.$